

Road Map Afiliados 360

Una guía estructurada para el desarrollo de la solución de datos, desde la ingesta de datos hasta la implementación de data solutions full-stack.

Contexto:

El presente proyecto se inspira en Confa caldas, para generar un escenario de desarrollo end to end de una solución de data full stack. Incluye el diseño, creación, implementación y optimización de: Data Pipelines ETL, Data Pipelines ELT, Transform with Athena, EDA with Panda or Poplars, Pyspark in Job ETL, ETL in Glue, Buckets S, Machine Learning, Rag with LongChain. En este proyecto se usará AWS como entorno cloud.

El producto final serán:

- ETL funcional.
- Data architecture definida e implementada.
- Data compliance. definida e implementada.
- Data set enriquecidos para Machine Learning o Deep Learning.
- Métricas y data set optimizado para Vector Database.
- Dashboard strategic.
- Rag estratégico: su función será facilitar la comprensión de insights, permitiendo un análisis más profundo, así como complementario para talento altamente técnico o traducción a lenguaje no técnico para personal sin alta expertise en data analysis.
- Data science para predicción de demanda Neta de servicios y/o subsidios.

Fase 1: Arquitectura y Cumplimiento de Datos

El objetivo es sentar las bases de la solución, definiendo la arquitectura y los estándares de cumplimiento.

- **Diseño de la Arquitectura de Datos:** Elaborar el Diagrama Entidad-Relación que modela los datos de afiliados, servicios y subsidios.
 - **Configuración del Entorno Cloud:**
 - Configurar los buckets de S3 para las capas de datos: RAW y TRANSFORM.
 - Establecer la arquitectura de datos definida e implementada.
 - **Definición de Data Compliance:**
 - Establecer las políticas y procedimientos para la calidad, seguridad y privacidad de los datos.
 - Asegurar que la data compliance esté definida e implementada en cada etapa del pipeline.
-

Fase 2: Ingesta y Transformación (Pipelines ETL/ELT)

En esta fase, los datos se ingieren, se limpian y se transforman para su uso.

- **Ingesta de Datos:**
 - Desarrollo de un script que simule la integración con APIs para generar más de 100,000 filas de datos sintéticos.
 - Alimentación del bucket S3 RAW con los datasets iniciales.
 - **Catalogación de Datos:**
 - Uso de AWS Glue Crawler para rastrear los datos crudos y catalogar sus esquemas.
 - **Transformación ETL:**
 - Implementación de un Job de AWS Glue con PySpark para la limpieza y la calidad del dato.
 - Conversión de los datos a formato Parquet y su carga en el bucket S3 TRANSFORM.
 - Garantizar un ETL funcional.
-

Fase 3: Análisis y Business Intelligence

El foco es generar valor a partir de los datos a través de insights visuales y análisis exploratorios.

- **Análisis Exploratorio de Datos (EDA):**
 - Realizar un EDA con Pandas o Polars para comprender la estructura y características de los datasets.
 - Implementación de Feature Engineering para enriquecer los datos.
 - **Optimización para BI:**
 - Uso de AWS Athena para ejecutar consultas SQL directas sobre los datos transformados.
 - Generación de datasets optimizados para las herramientas de BI.
 - **Visualización Estratégica:**
 - Conexión de Looker Studio y Power BI a los datos procesados.
 - Desarrollo e implementación del Dashboard estratégico.
-

Fase 4: Soluciones de IA Avanzadas (ML y LLMs)

Esta fase aprovecha el AI Engineering para construir soluciones predictivas y conversacionales.

- **Ciencia de Datos y ML:**
 - Creación de datasets enriquecidos para Machine Learning o Deep Learning.
 - Desarrollo de un modelo para la predicción de demanda neta de servicios y/o subsidios.
 - **Soluciones Conversacionales con RAG:**
 - Optimización de métricas y datasets para Vector Database.
 - Construcción e implementación de un RAG estratégico con LangChain.
 - Pruebas del RAG para asegurar su función de facilitar insights y traducir lenguaje técnico.
-

Productos Finales del Proyecto

- ETL funcional y Data Architecture definida e implementada.
- Data Compliance definida e implementada.
- Datasets enriquecidos para Machine Learning o Deep Learning.
- Métricas y dataset optimizados para Vector Database.
- Dashboard estratégico.
- RAG estratégico.
- Solución de Data Science para predicción de demanda Neta.